

分解在线策略蒸馏用于视觉-语言推理：梯度引导实现视觉定位

Hee Suk Yoon¹ Eunseop Yoon¹ Jaehyun Jang¹ SooHwan Eom¹ Ji Woo Hong¹ Mark Hasegawa-Johnson² Qi Dai³ Chong Luo³ Chang D. Yoo¹

摘要

尽管在策略蒸馏为训练小型推理模型提供了密集的监督信号，但其在多模态领域的优化动态仍未被充分探索。在本工作中，我们通过数学方法将损失分解为两个截然不同的组成部分——语言先验和视觉定位——从而挑战了视觉-语言模型(VLM)蒸馏的标准整体性观点。我们的分析发现，这两个分量的梯度向量几乎正交，这表明与教师模型的语言分布对齐的目标与匹配其视觉感知的目标在几何上是相互独立的。因此，标准优化被动地遵循一条次优的折衷轨迹，隐性地平衡这两个目标。基于视觉定位是视觉-语言推理主要瓶颈的假设，我们引入了**视觉梯度引导**

(VGS)，一种动态重新调整更新向量以优先考虑视觉子空间的方法。在多种蒸馏设置和复杂多模态基准上的实验结果表明，VGS显著优于标准的整体性在策略蒸馏公式，以极小的训练开销实现了更优越的定位能力。代码可在

<https://github.com/hee-suk-yoon/DecomposedOPD>获取。

1. 引言

近期推理模型的激增表明，通过使模型能够生成大量推理轨迹来扩展推理时计算，

¹韩国科学技术院 (KAIST)，²伊利诺伊大学厄巴纳-香槟分校 (UIUC)，³微软亚洲研究院 (MSRA)。通讯作者：Chang D. Yoo<cd.yoo@kaist.ac.kr>。

Proceedings of the 43rd International Conference on Machine Learning, 韩国首尔. PMLR 306, 2026. 版权所有 2026作者。




图1. 视觉梯度引导 (VGS) 优于标准整体蒸馏。我们比较了从 8B 教师模型蒸馏得到的学生模型的推理性能。VGS (紫色) 在多种多模态基准测试中始终优于标准基线 (绿色)，适用于 (a) 2B 和 (b) 4B 学生模型，展示了卓越的视觉定位能力。

生成中间推理步骤可以显著增强问题解决能力 (Comanici 等人, 2025; Yang 等人, 2025; 团队, 2025)。为了训练这些推理模型，基于可验证奖励的强化学习 (RLVR) 已成为数学和编程等领域的标准，在这些领域中，真实值易于验证 (Yang 等人, 2024; Guo 等人, 2025; Shao 等人, 2024; Yoon 等人, 2025a; 2026)。然而，对于较小的模型，RLVR 遇到了冷启动问题。稀疏的、基于结果的奖励无法为那些最初缺乏稳健推理策略的模型提供足够的信号。

在策略蒸馏 (Agarwal 等人, 2024; Xi 等人, 2024; Deng 等人, 2025) 提供了一种更优的替代方案。与依赖延迟结果反馈的 RLVR 不同，在策略蒸馏利用更强的教师模型，在学生模型自身的推理轨迹上提供密集的、令牌级别的监督。这克服了奖励稀疏问题，同时仍然让学生模型学习错误恢复和推理连贯性，类似于一位国际象棋教练在每一步棋中都提出批评，而不仅仅是对最终结果进行评判。

尽管在纯文本领域取得了成功，但在策略蒸馏在视觉-语言模型 (VLMs) 中仍未得到充分探索。例如，最近的模型如 Qwen3-VL (Bai 等人, 2025) 明确将蒸馏限制在纯文本




图2. 视觉梯度引导 (VGS) 概述。(左) 给定多模态查询 (图像 I 和提示 x)，我们从学生模型策略中采样一个轨迹 τ ，并在多模态 (I, x) 和单模态 $(x, \text{仅文本})$ 上下文中计算学生模型和教师模型的对数概率。(中) 我们将标准的单一目标分解为两个不同的组成部分：一个匹配教师模型纯文本分布的语言先验 ($\mathcal{L}_{\text{Lang}}$)，以及一个针对构建分布 q_T^* (该分布隔离教师模型的视觉信息增益) 的视觉定位目标 ($\mathcal{L}_{\text{Vis}}$)。(右) 我们的几何分析表明，标准蒸馏 ($\mathcal{L}_{\text{Standard}}$) 在这两个通常正交的目标之间充当被动折衷。VGS明确地将梯度更新引导向视觉子空间 ($\mathcal{L}_{\text{Vis}}$)，优先考虑感知保真度而非通用语言建模。

数据上，以微调LLM主干网络，却忽略了视觉定位的对齐。

我们发现，直接将标准的在线蒸馏扩展到多模态领域通常只会优化单一的、整体性的目标。在这项工作中，我们通过数学方法将损失分解为不同的语言先验和视觉定位组件，揭示了它们之间的根本张力 (图2)。通过梯度分析，我们识别出一种几何病态现象：这些组件的梯度向量经常正交。这表明，与教师模型的语言分布对齐的目标在几何上独立于匹配其视觉感知的目标。因此，标准蒸馏简单地累加这些梯度，被动地遵循一个次优的折中轨迹，无法严格保证感知保真度。

假设视觉定位是视觉-语言推理的主要瓶颈，我们引入了视觉梯度引导 (VGS)。这种梯度更新规则通过动态重新调整优化轨迹以最大化与教师模型视觉信息增益的对齐，从而明确优先考虑视觉子空间。通过确保模型将其更新预算集中在解决感知模糊性而非通用语言建模上，VGS实现了更优的对齐性能 (图1)。总之，我们的主要贡献如下：

- **VLM蒸馏的几何分析。**我们首次对VLM中的在策略蒸馏进行了梯度级分析，揭示了语言与视觉梯度之间的正交性，并识别出标准单块形式存在的次优“妥协轨迹”。

- **视觉梯度导向 (VGS)。**我们提出了一种新颖的优化目标，将视觉和语言监督分离开来，

引导梯度更新以严格强制视觉定位，同时不损害语言流畅性。

- **卓越的推理对齐。**我们证明，VGS在复杂多模态推理基准上显著优于在策略蒸馏的标准单块形式，且训练开销极小。

2. 背景与问题形式化

2.1. 自回归推理的蒸馏

在推理任务中，给定查询 x ，模型生成多步推理轨迹 τ 。形式上， $\tau = (h_1, \dots, h_T, \hat{y})$ 由一系列中间推理步骤 $\{h_k\}_{k=1}^T$ (通常称为思维链 (CoT)) 以及最终预测答案 $\hat{y}$ 组成。

在蒸馏的背景下，我们通过密集的令牌级监督来优化学生模型 p_S^θ ，使其匹配固定的教师模型 q_T 。我们使用序列级Kullback-Leibler (KL) 散度来量化教师模型与学生模型在轨迹 τ 上的差异，该散度定义为整个序列上平均令牌级前向KL散度：

$$\ell_{\text{Forward}}(\tau) \triangleq \frac{1}{|\tau|} \sum_{t=1}^{|\tau|} D_{\text{KL}}(q_T(\cdot | \tau_{<t}, x) \| p_S^\theta(\cdot | \tau_{<t}, x)).$$

符号 $q_T(\cdot | \tau_{<t}, x)$ 和 $p_S^\theta(\cdot | \tau_{<t}, x)$ 分别表示教师模型和学生模型在步骤 t 上对词汇表 $\mathcal{V}$ 的完整类别分布。

标准序列级知识蒸馏 (SeqKD) (Kim & Rush, 2016; Taori et al., 2023)，通常被称为高策略蒸馏，最小化前向KL散度。该目标计算严格从教师模型中采样的轨迹上的期望序列散度：

$$\mathcal{L}_{\text{Off-Policy}} = \mathbb{E}_{\tau \sim q_T} [\ell_{\text{Forward}}(\tau)]. \quad (1)$$

尽管前向KL散度在初始化阶段有效，但它具有模式覆盖性，会强制学生模型将概率质量分配给教师模型分布的所有模式。对于推理任务而言，这往往并非最优——若学生模型缺乏能力来建模教师模型的完整复杂性，它将被迫以低概率转移来连接不同模式，导致幻觉和不可信的推理链（Gu et al., 2024; Agarwal et al., 2024）。此外，这种离线策略方法存在暴露偏差：学生模型从未被训练去从自身的自回归错误中恢复。

为了应对这些局限性，近期的工作（Agarwal等人, 2024; Gu等人, 2024）提倡采用**基于策略的蒸馏**，通过**反向KL散度**。我们首先定义轨迹上的反向KL散度，对于轨迹 τ 为：

$$\ell_{\text{Reverse}}(\tau) \triangleq \frac{1}{|\tau|} \sum_{t=1}^{|\tau|} D_{\text{KL}}(p_S^\theta(\cdot | \tau_{<t}, x) \parallel q_T(\cdot | \tau_{<t}, x)).$$

该方法最小化了从学生模型中采样的轨迹上的期望序列级差异：

$$\mathcal{L}_{\text{On-Policy}} = \mathbb{E}_{\tau \sim p_S^\theta} [\ell_{\text{Reverse}}(\tau)]. \quad (2)$$

这种公式有两个主要优势。首先，反向KL是**寻找模式**的；它惩罚学生模型生成在教师模型下不太可能的样本（ $q_T \approx 0$ ），优先考虑高置信度的推理路径而非广泛覆盖（Gu等人, 2024; Agarwal等人, 2024）。其次，通过采样 $\tau \sim p_S^\theta$ ，学生模型从自身的推理路径中学习（在线策略），有效缩小了训练与推理之间的间隙。

2.2. 标准的一体化多模态目标

在视觉-语言领域，我们将这种在线策略公式扩展到包含视觉上下文。给定一个输入图像 I 和文本提示 x ，我们将**整体轨迹层面散度**定义为轨迹 τ 的：

$$\ell_{\text{Standard}}(\tau) \triangleq \frac{1}{|\tau|} \sum_{t=1}^{|\tau|} D_{\text{KL}}(p_S^\theta(\cdot | \tau_{<t}, I, x) \parallel q_T(\cdot | \tau_{<t}, I, x)). \quad (3)$$

标准方法优化从学生模型中采样的轨迹上这个量的期望：

$$\mathcal{L}_{\text{Standard}} = \mathbb{E}_{\tau \sim p_S^\theta(\cdot | I, x)} [\ell_{\text{Standard}}(\tau)]. \quad (4)$$

然而，正如我们接下来所展示的，这种方法将学习信号视为一个整体，模糊了语言先验匹配与视觉定位的独特贡献。

3. 重新审视视觉语言中的在策略蒸馏

3.1. 分解单一目标

通过应用贝叶斯法则，我们可以对任意多模态生成器 p 的条件概率进行分解，以分离目标的底层组件。对数似然分解为一个语言先验、一个视觉似然，以及一个序列无关的常数：

$$\log p(\tau | I, x) = \underbrace{\log p(\tau | x)}_{\text{Language Prior}} + \underbrace{\log p(I | \tau, x)}_{\text{Visual Likelihood}} - \log p(I | x). \quad (5)$$

将此恒等式应用于学生模型 p_S^θ 和教师模型 q_T 后，可以发现标准的单一目标隐式地结合了两个不同的目标：匹配语言先验（推理风格）和匹配视觉似然（感知基础）。注意，证据项 $\log p(I | x)$ 相对于生成的序列 τ 是常数，仅充当归一化因子。

I. 语言先验匹配 ($\mathcal{L}_{\text{Lang}}$)。这一目标将学生模型的单模态分布 $p_S^\theta(\cdot | x)$ 与教师模型的 $q_T(\cdot | x)$ 对齐，确保基本推理风格独立于视觉上下文 I 进行迁移。我们首先定义**轨迹级语言散度**：

$$\ell_{\text{Lang}}(\tau) \triangleq \frac{1}{|\tau|} \sum_{t=1}^{|\tau|} D_{\text{KL}}(p_S^\theta(\cdot | \tau_{<t}, x) \parallel q_T(\cdot | \tau_{<t}, x)). \quad (6)$$

我们最小化该散度的期望。关键在于，虽然我们在单模态分布上计算梯度，但从全模态策略 $p_S^\theta(\cdot | I, x)$ 中采样轨迹 τ ，以保持与学生实际生成分布的同策略对齐：

$$\mathcal{L}_{\text{Lang}} = \mathbb{E}_{\tau \sim p_S^\theta(\cdot | I, x)} [\ell_{\text{Lang}}(\tau)]. \quad (7)$$

II. 视觉定位匹配 ($\mathcal{L}_{\text{Vis}}$)。该目标独立出了视觉似然项，即式 (5) 中所定义的项。该项 $\log p(I | \tau, x)$ 表示模型的**感知灵敏度**，量化了生成推理在因果上解释视觉输入的能力。尽管在自回归模型中显式计算似然是不可行的，但贝叶斯公式揭示出，该似然与可计算的**视觉信息增益**——即后验与先验的对数比率——仅相差一个序列无关的常数：

$$\log p(I | \tau, x) = \underbrace{[\log p(\tau | I, x) - \log p(\tau | x)]}_{\text{Visual Information Gain}} + \log p(I | x). \quad (8)$$

由于证据项 $\log p(I | x)$ 仅依赖于图像，并且对于轨迹 τ 是常数，匹配教师模型的信息增益在数学上等同于对齐学生模型的视觉感知。




图3. 梯度动态的几何分析。(a) 随着视觉依赖性的增加，语言梯度与视觉梯度之间的角度增大，接近正交性在高依赖性区域。钝角 ($> 90^\circ$, 虚线框)在极端情况下特别促使了语言保留正则化器 (公式16) 以防止梯度冲突。(b, c) 标准的整体梯度 ($\nabla \mathcal{L}_{\text{Standard}}$) 充当被动的平分线，保持相对静态的折中方向 ($\approx 40^\circ - 50^\circ$) 相对于两个组件，即使感知需求达到最大 (Bin 9)，也未能完全与视觉信号对齐。

形式上，我们通过构建一个视觉目标分布 q_T^* 来实现这一点，该分布保留了学生模型的语言先验，但用教师模型的视觉似然替换其自身的视觉似然：

$$q_T^*(\tau | I, x) \propto p_S^\theta(\tau | x) \cdot q_T(I | \tau, x). \quad (9)$$

将教师模型的似然的贝叶斯展开代入公式9，在log空间中得到了可处理的目标logits：

$$\log q_T^*(\tau | I, x) = \log p_S^\theta(\tau | x) + (\log q_T(\tau | I, x) - \log q_T(\tau | x)) - \log Z^*. \quad (10)$$

关键地，边际证据项 $\log q_T(I | x)$ 作为标量偏移作用于所有 token。在我们的自回归公式中，这一常数被吸收到局部配分函数 Z^* 中，该函数在每一步解码时通过 Softmax 算子隐式计算。

我们最终定义针对这一目标的轨迹级视觉散度 $\ell_{\text{Vis}}(\tau)$ 及其对应的期望：

$$\ell_{\text{Vis}}(\tau) \triangleq \frac{1}{|\tau|} \sum_{t=1}^{|\tau|} D_{KL}(p_S^\theta(\cdot | \tau_{<t}, I, x) \| q_T^*(\cdot | \tau_{<t}, I, x)),$$

$$\mathcal{L}_{\text{Vis}} = \mathbb{E}_{\tau \sim p_S^\theta(\cdot | I, x)} [\ell_{\text{Vis}}(\tau)]. \quad (11)$$

3.2. 梯度动力学的几何分析

为了理解标准整体目标的优化动力学，我们实证分析了其分解梯度向量之间的几何关系。具体而言，我们研究了标准更新 $\nabla \mathcal{L}_{\text{Standard}}$ 如何相对于具有不同视觉依赖程度的标记上的语言先验 ($\nabla \mathcal{L}_{\text{Lang}}$) 和视觉定位 ($\nabla \mathcal{L}_{\text{Vis}}$) 梯度进行定位。

完整的多模态学生模型策略， $\tau \sim p_S^\theta(\cdot | I, x)$ 。为了对每个生成标记的感知必要性进行分类，我们使用教师模型的分布定义了视觉依赖度评分 (VDS)：

$$\text{VDS}_t = D_{KL}(q_T(\cdot | \tau_{<t}, I, x) \| q_T(\cdot | \tau_{<t}, x)). \quad (12)$$

我们根据所有生成 token 的 VDS 将其划分为 10 个等频分位数；bin 0 表示视觉依赖最小的 token，而 bin 9 表示教师模型高度依赖视觉证据的 token。

图3展示了这些区间之间的角度关系。我们的分析强调了两个关键的几何性质：

I. 视觉极值处的正交性 (图3-(a))。我们首先考察语言梯度与视觉梯度之间的关系。我们观察到一种明显的单调趋势：随着标记的视觉依赖性增加， $\nabla \mathcal{L}_{\text{Lang}}$ 和 $\nabla \mathcal{L}_{\text{Vis}}$ 之间的角度增大。

- 在低依赖区域 (bin 0) 中，梯度适度对齐 ($\theta \approx 60^\circ$)。
- 在高依赖区域 (bin 9)，梯度变得几乎正交 ($\theta \approx 92^\circ$)。

II. 标准损失作为静态平分线 (图3-(b),(c))。接下来，我们分析标准整体梯度的方向 $\nabla \mathcal{L}_{\text{Standard}}$ 。图3-(b)和(c)显示了标准梯度相对于视觉和语言分量的角度。

我们观察到标准目标始终保持一种“妥协”轨迹。即使对于视觉上最关键的标记 (Bin 9)，理想的更新按理应与视觉证据对齐，但 $\nabla \mathcal{L}_{\text{Standard}}$ 保留了从 $\nabla \mathcal{L}_{\text{Vis}}$ 的显著偏移 $\approx 42^\circ$ 。同时，它与语言梯度也保持相似的距离。




图4. 训练动态. 我们比较了不同方法在训练过程中分解损失分量的演化。(a) 视觉定位 ($\mathcal{L}_{Vis}$): VGS (蓝色) 相较于标准单一基线 ($\mathcal{L}_{Standard}$, 绿色) 显著加快了视觉学习, 尤其是对于高依赖性的令牌 (区间7-9)。(b) 语言先验 ($\mathcal{L}_{Lang}$): 在没有正则化的情况下, 激进的视觉引导 ($\gamma = 2.0$, 深蓝色) 导致语言先验发散 (“遗忘学习”), 尤其是在高冲突视觉区域 (区间7-9)。我们最终采用语言保持方法 ($\mathcal{L}_{VGS-LP}$, 粉色) 成功阻止了这种退化, 同时保持了优越的视觉定位。

($\approx 50^\circ$)。这种**几何刚性**表明标准目标充当一个**被动平分线**：它在语言和视觉方向之间创建一个固定的平均值，将两个信号视为同等重要。

假设：打破优化对称性. 我们假设标准目标函数是次优的，因为它在一个固有不对称的任务上施加了几何对称性。由于性能受到**感知瓶颈**的制约，并且语言梯度与视觉改进正交，标准的折衷更新效率低下。我们提出，明确地**引导**梯度朝向视觉子空间引入了一种必要的归纳偏置，优先解决感知模糊性而非通用语言建模。

4. 方法：视觉梯度引导

受第3.2节中观察到的几何病理现象启发，我们提出**视觉梯度引导 (VGS)**，以构建一个优先考虑视觉子空间的梯度更新。

导向目标. 我们首先定义轨迹级别的导向目标 $\ell_{VGS}(\tau)$ ，该目标通过一个辅助视觉项增强了标准蒸馏损失 $\ell_{Standard}(\tau)$ ：

$$\ell_{VGS}(\tau) \triangleq \ell_{Standard}(\tau) + \gamma \ell_{Vis}(\tau), \quad (13)$$

其中 $\ell_{Vis}(\tau)$ 对应于在等式 (Eq.) 中推导出的视觉定位目标 11, 并且 $\gamma \geq 0$ 是引导系数 它控制视觉校正的强度。最终的损失函数是最小化预期引导目标：

$$\mathcal{L}_{VGS} = \eta_{VGS}(\gamma) \cdot \mathbb{E}_{\tau \sim p_S^\theta(\cdot | I, x)} [\ell_{VGS}(\tau)]. \quad (14)$$

梯度范数归一化. 为了确保优化过程保持稳定，我们引入了一个缩放因子 $\eta_{VGS}(\gamma)$ 。

我们定义 $\eta_{VGS}(\gamma)$ ，使得引导梯度的范数等于原始标准梯度的范数：

$$\eta_{VGS}(\gamma) \triangleq \frac{\|\nabla_{\theta} \mathcal{L}_{Standard}\|_2}{\|\nabla_{\theta} \mathcal{L}_{Standard} + \gamma \nabla_{\theta} \mathcal{L}_{Vis}\|_2}. \quad (15)$$

这种归一化确保VGS只改变方向的更新——将其引导至视觉子空间——而不改变幅度的参数步长。这有效地将“引导” (由 γ) 与“学习率” (由优化器控制) 分离，这是多任务学习中广泛采用的稳定性原则 (Chen等人, 2018)。在实践中，为了避免动态范数计算的计算开销，我们设置 $\eta_{VGS}(\gamma)$ 为依赖于 γ 的固定常数，正如附录A 中的实证分析所确认的，梯度幅度比率在整个训练过程中保持稳定。

缓解破坏性梯度干扰. 虽然VGS能有效将生成过程引导至视觉定位，但我们的分析 (图3-(a)) 揭示，视觉依赖性最高的词元在视觉梯度和语言梯度之间呈现**钝角** ($> 90^\circ$)。在这种情形下，仅针对视觉定位进行优化会导致语言梯度上的负投影，实质上是“遗忘”语言先验。图4 从经验上证实了这一点：在仅使用 $\mathcal{L}_{VGS}$ 进行训练时，高VDS词元的语言先验匹配损失 ($\mathcal{L}_{Lang}$) 会显著发散。

为了防止这一点，我们引入了一个**语言保留 (LP)** 正则化器。我们选择性地将此术语应用于**由VDS排名前30%的令牌** (式12; 对应Bins 7-9)，其中这种梯度冲突最为普遍。我们定义轨迹级别的保留损失为：

$$\ell_{LP}(\tau) \triangleq \frac{1}{|\tau|} \sum_{t=1}^{|\tau|} \left(\mathbb{1}[\text{VDS}_t > Q_{0.7}] \cdot D_{KL}(p_S^\theta(\cdot | \tau_{<t}, x) \| q_T(\cdot | \tau_{<t}, x)) \right), \quad (16)$$

表1. 视觉-语言推理基准的主要结果。我们将视觉梯度引导（VGS）的蒸馏性能与标准整体基线进行比较。所有学生模型（2B和4B）均从同一使用GRPO训练的Qwen3-VL- 8B-Instruct教师模型蒸馏而来。VGS在所有基准上始终优于标准方法，在贪婪解码（Top-1准确率）和随机采样（Acc@16）中均取得了更高的准确率。

基准	初始学生模型		标准在策略蒸馏		VGS在策略蒸馏（我们的）		改进	
	Top-1准确率	Top-1准确率	Top-1准确率	Acc@16	Top-1准确率	Acc@16	Top-1准确率	Acc@16
	(贪婪)	(贪婪)	(贪婪)	(T=1.0)	(贪婪)	(T=1.0)	(贪婪)	(T=1.0)
	8B	2B	Qwen3-VL-8B-Instruct → Qwen3-VL-2B-Instruct					
MMMU-Pro-4	62.03	34.51	45.83	47.33	48.07	48.34	+2.14	+1.01
LogicVista	60.01	36.83	45.53	46.19	48.88	46.47	+3.35	+0.28
MathVerse-VD	79.63	35.88	56.02	59.68	58.10	60.10	+2.08	+0.42
MathVerse-VO	73.85	35.32	54.59	55.76	56.19	56.52	+1.61	+0.76
VisualPuzzles	43.15	13.36	28.08	30.64	31.76	31.59	+3.68	+0.95
MathVision	44.14	14.28	24.14	25.37	25.59	26.73	+1.45	+1.36
VlmsAreBlind	66.79	49.03	51.86	50.52	54.11	53.24	+2.26	+2.72
Average	61.37	31.32	43.74	45.07	46.10	46.14	+2.37	+1.07
	8B	4B	Qwen3-VL-8B-Instruct → Qwen3-VL-4B-Instruct					
MMMU-Pro-4	62.03	48.93	55.79	56.43	56.86	56.86	+1.07	+0.43
LogicVista	60.01	47.10	55.80	56.43	58.70	56.98	+2.90	+0.55
MathVerse-VD	79.63	57.18	71.53	73.60	74.31	73.89	+2.78	+0.29
MathVerse-VO	73.85	53.67	70.18	68.33	71.10	68.53	+0.92	+0.20
VisualPuzzles	43.15	26.54	40.75	39.17	40.31	39.22	-0.44	+0.05
MathVision	44.14	31.40	37.96	39.26	40.59	40.16	+2.63	+0.90
VlmsAreBlind	66.79	61.94	64.46	64.82	65.49	65.92	+1.03	+1.10
Average	61.37	46.68	56.64	56.86	58.12	57.27	+1.56	+0.50

其中 $Q_{0.7}$ 表示视觉依赖度评分分布的第70百分位数阈值。该术语仅在视觉引导信号可能具有破坏性时，才对偏离教师模型语言先验的行为施加惩罚。我们将其纳入最终的轨迹级目标：

$$\begin{aligned}\ell_{\text{VGS-LP}}(\tau) &= \ell_{\text{VGS}}(\tau) + \lambda \ell_{\text{LP}}(\tau) \\ &= \ell_{\text{Standard}}(\tau) + \gamma \ell_{\text{Vis}}(\tau) + \lambda \ell_{\text{LP}}(\tau),\end{aligned}\quad (17)$$

其中 γ 作为主要引导系数（通常 $\gamma \geq 1$ ）以驱动视觉适应，而 λ 作为保守的正则化权重（例如 $\lambda \approx 0.01$ ）以选择性地防止灾难性遗忘。总损失通过该目标函数的期望最小化，并由自适应归一化因子缩放 $\eta_{\text{VGS}}(\gamma)$ 在方程 15：

$$\mathcal{L}_{\text{VGS-LP}} = \eta_{\text{VGS}}(\gamma) \cdot \mathbb{E}_{\tau \sim p_S^g(\cdot|I,x)} [\ell_{\text{VGS-LP}}(\tau)]. \quad (18)$$

如图 4所示，该公式成功缓解了语言先验的发散，确保模型即使在高度冲突的视觉场景中也能保持其推理能力。

5. 实验设置

5.1. 模型与数据集

我们在 **Vision-SR1-47K** 数据集 (Liet et al., 2025) 上进行训练。该数据集包含47k个三元组 (I, x, y) ，

包含一张图像 I ，一个问题 x ，和一个可验证的最终答案 y 。为了进行对照实验，我们避免使用训练混合物未知的现成推理模型。相反，我们通过 Vision-SR1-47K 数据集上使用群体相对策略优化（GRPO）(Shao et al., 2024) 对 **Qwen3-VL-8B-Instruct** (Bai et al., 2025) 进行2轮微调，从而训练一个推理教师模型。完整实现细节见附录B.1。对于学生策略，我们使用较小的 **Qwen3-VL-2B-Instruct** 和 **Qwen3-VL-4B-Instruct** (Bai et al., 2025)。

我们在七个视觉-语言推理基准上进行评估。对于数学推理，我们使用了 **MathVision** (Wang 等人, 2024) 和 **MathVerse** (Zhang 等人, 2024)，并报告了视觉主导 (VD) 和纯视觉 (VO) 子集的结果。对于视觉逻辑，我们使用了 **LogicVista** (Xiao 等人, 2024)、**VisualPuzzles** (Song 等人, 2025) 和 **VlmsAreBlind** (Rahmanzadehgervietal., 2024)。最后，我们使用 **MMMU-Pro** (Yue 等人, 2024) 在其4选项设置中测试多学科推理。

5.2. 实现细节

提示格式。为实现结构对齐，教师模型（在GRPO过程中）和学生模型（在蒸馏过程中）均使用统一系统提示。这强制执行严格的推理格式，要求模型明确区分内部推理轨迹与最终答案。完整提示模板见附录B.4。

超参数。我们在所有实验中，使用引导系数 $\gamma = 2.0$ 和 $\lambda = 0.01$ 优化等式 (7) = 0.41 中的目标函数。对于梯度归一化，我们为Qwen3-VL-2B-Instruct设置 $\eta(\gamma) = 0.36$ ，为Qwen3-VL-4B-Instruct设置 $\eta(\gamma) = 0.36$ ，如附录A中所论证。为公平比较，所有其他训练配置均保持与基线一致。完整的超参数详情及敏感性分析见附录B.2、B.3。

6. 实验结果

我们通过将GRPO训练的Qwen3-VL-8B-Instruct教师模型蒸馏至2B和4B学生模型中，评估了视觉梯度引导（VGS）方法。如表1所示，VGS在全部七个视觉-语言基准上持续优于标准整体基线。当师生能力间隙较大时，改进尤为显著。在Qwen3-VL-8B $\rightarrow$ Qwen3-VL-2B设定下，VGS实现了平均贪婪准确率（Top-1准确率）为**46.10%**，比基线（43.74%）显著高出 **+2.37%**。这一提升主要源于视觉密集型任务，如VisualPuzzles（+3.68%）和LogicVista（+3.35%）的较大改进。该趋势在更大规模的Qwen3-VL-4B 学生模型上得以延续，VGS将平均Top-1准确率提升至**58.12%**（+1.56%超过基线），有效缩小了与8B教师模型（61.37%）的差距。

此外，我们通过随机采样（Acc@16）评估策略的鲁棒性，该指标计算为16次独立生成（温度 $T = 1.0$ 上的平均准确率，而VGS在两个规模下均能获得更高的平均准确率。我们在附录C 中提供了计算开销对比，并在第9节展示了训练动态。

7. 验证非对称成熟度假设

我们方法的一个核心前提是**非对称成熟度假设**（第3.2节）：我们认为视觉定位是主要的优化瓶颈，而语言先验已经相对鲁棒。为了验证这一点，我们进行了一项反向引导实验：如果我们把梯度引向语言先验，会发生什么？

我们定义 **LanguageSteering** 目标与 VGS-LP 对称。该目标将生成过程引向单模态语言先验 ($\mathcal{L}_{\text{Lang}}$)，同时严格保留高依赖令牌上的视觉定位：

$$\mathcal{L}_{\text{Lang-Steer}} = \eta_{\text{Lang}}(\gamma_{\text{Lang}}) \cdot \mathbb{E}_{\tau \sim p_S^{\theta}(\cdot | I, x)} \left[\ell_{\text{Standard}}(\tau) + \gamma_{\text{Lang}} \ell_{\text{Lang}}(\tau) + \lambda \ell_{\text{VP}}(\tau) \right], \quad (19)$$

其中 $\eta_{\text{Lang}}(\gamma_{\text{Lang}})$ 是自适应缩放因子，定义为




图5. 验证非对称成熟度假设。引导向语言匹配方向会降低相对于标准基线的准确率，而引导向视觉子空间则能带来一致的性能提升。

类似于公式15，但是使用语言梯度方向以保持优化稳定性：

$$\eta_{\text{Lang}}(\gamma) \triangleq \frac{\|\nabla_{\theta} \mathcal{L}_{\text{Standard}}\|_2}{\|\nabla_{\theta} \mathcal{L}_{\text{Standard}} + \gamma_{\text{Lang}} \nabla_{\theta} \mathcal{L}_{\text{Lang}}\|_2}. \quad (20)$$

术语 $\ell_{\text{VP}}(\tau)$ 是**视觉保留**正则化器，它惩罚与教师模型的视觉分布之间的偏差 q_T^* （式10），具体在视觉定位最为关键的标记上：

$$\ell_{\text{VP}}(\tau) \triangleq \frac{1}{|\tau|} \sum_{t=1}^{|\tau|} \left(\mathbb{1}[\text{VDS}_t > Q_{0.7}] \cdot D_{KL}(p_S^{\theta}(\cdot | \tau_{<t}, x) \parallel q_T^*(\cdot | \tau_{<t}, x)) \right). \quad (21)$$

类似于我们的 VGS-LP 公式（式 17），我们将 λ 设置为一个小的正则化值（即 0.01）。这确保了对称的比较，其中两个目标引导一个主要模态，同时保护另一个模态免受灾难性遗忘。

图 5 比较了视觉引导 ($\gamma > 0$) 与语言引导 ($\gamma_{\text{Lang}} > 0$) 的性能。如图所示（其中 y 轴代表表 1 中列出的 7 个基准测试的 **average** 准确率），增加视觉引导系数 γ 带来了改进，将 **average** 从基线提升。相比之下，引导向语言先验 ($\gamma_{\text{Lang}} > 0$) 会损害性能，准确率下降至低于基线。这证实了模型的语言先验已经足够稳健；强制向它更新会消耗优化预算而没有任何收益。然而，视觉模态仍然是关键瓶颈，对有针对性的梯度注入积极响应。

8. 强化学习微调 + 在策略蒸馏

正如Agarwal等人 (2024) 所指出的，在策略蒸馏可以自然地与强化学习 (RL) 相结合

表2. RL上的消融结果 + 在策略蒸馏. 我们评估了将蒸馏目标集成到GRPO训练循环中的有效性, 使用 Qwen3-VL-2B-Instruct。我们的视觉梯度导向 (VGS) 方法与与RL结合时, 始终优于标准的单一蒸馏基线。

基准	初始 学生模型 (2B)	GRPO		GRPO + 标准 同策略蒸馏		GRPO + VGS 在线策略蒸馏 (我们的)		改进	
	Top-1准确率 (贪婪)	Top-1准确率 (贪婪)	Acc@16 (T=1.0)	Top-1准确率 (贪婪)	Acc@16 (T=1.0)	Top-1准确率 (贪婪)	Acc@16 (T=1.0)	Top-1准确率 (贪婪)	Acc@16 (T=1.0)
MMMU-Pro-4	34.51	47.66	49.59	45.85	46.86	50.29	49.26	+4.44	+2.40
LogicVista	36.83	46.43	44.24	44.64	45.28	46.88	46.01	+2.24	+0.73
MathVerse-VD	35.88	59.03	59.68	61.11	60.43	64.81	61.44	+3.70	+1.01
MathVerse-VO	35.32	53.67	56.47	58.03	55.89	57.80	57.70	-0.23	+1.81
VisualPuzzles	13.36	30.22	31.64	31.08	31.36	31.68	32.23	+0.60	+0.87
MathVision	14.28	27.20	28.02	25.26	25.98	27.17	27.52	+1.91	+1.54
VlmsAreBlind	49.03	49.61	50.16	51.90	50.77	51.74	51.85	-0.16	+1.08
Average	31.32	44.83	45.68	45.41	45.22	47.20	46.57	+1.79	+1.35




图6. 纯蒸馏与GRPO设置的训练动态分析。(a) Qwen3-VL-2B和4B学生模型在在策略蒸馏过程中的平均准确率演化。与标准整体基线相比, VGS在整个训练过程中取得了更高的平均准确率。(b) GRPO框架分析(使用Qwen3-VL-2B)。左: VGS与GRPO结合获得了最高的准确率轨迹, 优于纯GRPO和GRPO + 标准蒸馏。右: 纯GRPO存在长度爆炸问题, 而两种蒸馏方法均能将生成长度正则化至教师模型的平均水平; 然而, VGS在这种高效的长度约束下实现了显著更高的准确率。

目标, 因为两种范式都涉及直接从学生模型的当前策略中采样轨迹。我们研究提出的向视觉子空间的引导 ($\mathcal{L}_{\text{VGS-LP}}$, 公式 17) 是否能在使用 GRPO 进行微调时增强这种协同作用 (Shao 等人, 2024)。

按照Agarwal等人 (2024) 的公式, 我们将统一训练目标构建为RL奖励与蒸馏约束的加权凸组合。我们将总目标 $\mathcal{J}_{\text{Total}}(\theta)$ 定义为:

$$\mathcal{J}_{\text{Total}}(\theta) = \mathbb{E}_{\{\tau_i\}_{i=1}^G \sim p_S^\theta} \left[\frac{1}{G} \sum_{i=1}^G \left((1 - \alpha) \mathcal{O}_{\text{GRPO}}(\tau_i) - \alpha \ell_{\text{VGS-LP}}(\tau_i) \right) \right], \quad (22)$$

其中 $\mathcal{O}_{\text{GRPO}}(\tau_i)$ 是标准的GRPO代理目标 (裁剪优势), 不含 KL 惩罚, $\ell_{\text{VGS-LP}}$ 则作为视觉蒸馏正则化项。我们比较

在Vision-SR1-47K数据集上的三种训练配置 (Li等人, 2025):

GRPO (标准): 纯强化学习优化, 最大化正确性奖励 (等同于 $\alpha = 0$)。

2. GRPO + 标准知识蒸馏: 由标准单体蒸馏损失正则化的RL。这对应于公式22其中 $\ell_{\text{VGS-LP}}$ 被替换为 ℓ_{Standard} 。我们设置 α 为0.3

如表 2所示, 虽然标准知识蒸馏 (Standard-KD) 相比纯GRPO在稳定性上有所提升, 但它受到妥协效应的影响, 将策略拉回教师模型的通用均值方向。**GRPO + VGS** 显著优于两种基线。通过使用VGS作为正则化器, 我们施加了一个与RL奖励正交的约束: RL目标优化的是

正确答案，而VGS确保了推理过程始终保持视觉上的基础。这表明VGS是一种通用的目标函数，可以嵌入到各种后训练范式之中，以强制执行感知保真度。

9. 训练动态

在图6中，我们展示了训练期间所有7个基准数据集的平均准确率演变。首先，图6-(a)比较了在策略蒸馏设置下的2B和4B学生模型。在两个规模上，与标准单一基线相比，我们的VGS方法始终实现更高的准确率曲线，验证了视觉梯度引导的有效性。

此外，图6-(b)（左）显示了在RL（GRPO）+在策略蒸馏设置中的平均准确度，该设置在第8节中介绍。虽然添加蒸馏总体上加速了训练，但我们的VGS产生了明显更高的准确度曲线。图6-(b)（右）展示了生成长度动态。我们观察到，两种蒸馏目标都约束学生模型向教师模型的平均生成长度收敛，防止了标准GRPO中出现的长度爆炸。值得注意的是，与标准同策略蒸馏相比，VGS在此受限长度下实现了显著更高的准确度，进一步验证了视觉梯度引导对于推理效率的有效性。

10. 相关工作

用于推理的强化学习 超越基础的RLHF和偏好优化范式（Christiano等人，2017；Bai等人，2022；Ouyang等人，2022；Yoon等人，2024；Rafailov等人，2023；Yoon等人，2025b），最近在多样化任务上进行的大规模强化学习（RL）训练显著提升了LLM的通用推理能力（Guo等人，2025；Team等人，2025；Lambert等人，2024）。这些进步主要由基于可验证奖励的强化学习（RLVR）框架推动（Yang等人，2024；Guo等人，2025；Shao等人，2024；Yoon等人，2025a；2026）。

然而，标准RLVR环境中的一个持久挑战是结果奖励通常是稀疏的，仅在标记序列的最末尾生成。为了解决这个信用分配难题，最近的几项研究开发了过程奖励模型（PRMs）（李和李，2025；程等人，2026；张等人，2025

正在从强大的教师模型中获取密集的、令牌级别的监督（Yang等人，2025；Guha等人，2025；Agarwal等人，2024）。

在策略知识蒸馏 知识蒸馏（KD）已成为一种流行范式，通过利用较大的教师模型的监督来开发高效的小型大语言模型（SLMs）（Yang等人，2025；Team等人，2024；Guo等人，2025；Muralidharan等人，2024；Gu等人，2024；Agarwal等人，2024）。Gu等人（2024）证明，反向KL散度比前向KL散度更能有效防止学生模型高估教师分布中固有的低概率区域。此外，Agarwal等人（2024）通过实验分析了在策略蒸馏（学生模型生成训练数据）与离策略设置之间的权衡，以及反向KL目标和前向KL目标之间的平衡。在这项工作中，我们采用带有反向KL散度的在策略蒸馏来增强指令微调模型的推理能力，同时尽量减少与学生模型初始分布之间的偏移（Gu等人，2024）。

MLLMs中的以视觉为中心的知识蒸馏 视觉-语言领域中的知识蒸馏近来作为开发高效、小规模多模态大语言模型（MLLMs）的关键策略而获得了大量研究关注。Cai等人(2025)利用该方法从大规模教师模型中蒸馏出广泛的视觉指令跟随能力，注入高效的学生模型。此外，为了解决更细粒度的感知对齐，Jain等人(2025)引入了视觉嵌入蒸馏来传递空间知识，而Kim等人(2025)提出了一个显式的注意力对齐框架，使学生模型能够继承教师模型的组合推理模式。与依赖辅助编码器或显式特征对齐的计算密集型方法不同，我们的方法通过教师模型的分解输出logits直接引导学生的视觉定位，从而最小化复杂性。

11. 结论

我们发现标准单目标的一个根本局限性：由于MLLM模态的不对称成熟度，梯度作为被动平分线无法纠正较弱的视觉信号。我们提出**视觉梯度引导（VGS）**，通过在优化过程中明确优先处理视觉子空间来解决这一问题。实验表明，VGS不仅优于标准蒸馏，还能作为RL（GRPO）微调的关键正则化器。这些结果证实，打破优化对称性，而非平等对待模态，是解锁忠实多模态基础的关键。

致谢

本研究由韩国政府（MSIT）资助的信息与通信技术规划与评估（IITP）项目（编号：RS-2022-II0951，开发通过提问学习的不确定性感知智能体）支持，并得到MSIT（科学与ICT部）在数字领域全球研究支持项目（RS-2024-00436680）下的资助，该项目由IITP（信息与通信技术规划与评估研究所）监督。本项目还得到了微软亚洲研究院的支持。

影响声明

本文介绍的工作旨在推动机器学习领域的发展。我们的工作可能产生许多潜在的社会影响，但在此我们认为无需特别强调其中任何一项。

参考文献

Agarwal, R., Vieillard, N., Zhou, Y., Stanczyk, P., Garea, S. R., Geist, M., 和 Bachem, O. 语言模型的在策略蒸馏：从自我生成的错误中学习。在 第十二届国际学习表征会议, 2024年。

Bai, S., Cai, Y., Chen, R., Chen, K., Chen, X., Cheng, Z., Deng, L., Ding, W., Gao, C., Ge, C., Ge, W., Guo, Z., Huang, Q., Huang, J., Huang, F., Hui, B., Jiang, S., Li, Z., Li, M., Li, M., Li, K., Lin, Z., Lin, J., Liu, X., Liu, J., Liu, C., Liu, Y., Liu, D., Liu, S., Lu, D., Luo, R., Lv, C., Men, R., Meng, L., Ren, X., Ren, X., Song, S., Sun, Y., Tang, J., Tu, J., Wan, J., Wang, P., Wang, P., Wang, Q., Wang, Y., Xie, T., Xu, Y., Xu, H., Xu, J., Yang, Z., Yang, M., Yang, J., Yang, A., Yu, B., Zhang, F., Zhang, H., Zhang, X., Zheng, B., Zhong, H., Zhou, J., Zhou, F., Zhou, J., Zhu, Y., and Zhu, K. Qwen3-VL技术报告, 2025年。URL <https://arxiv.org/abs/2511.21631>.

Bai, Y., Jones, A., Ndousse, K., Askell, A., Chen, A., Das-Sarma, N., Drain, D., Fort, S., Ganguli, D., Henighan, T., 等. 通过人类反馈的强化学习训练一个有用且无害的助手。 *arXiv预印本 arXiv:2204.05862*, 2022.

Cai, Y., Zhang, J., He, H., He, X., Tong, A., Gan, Z., Wang, C., Xue, Z., Liu, Y., 和 Bai, X. Llava-kd: 一种蒸馏多模态大语言模型的框架。在 *IEEE/CVF国际计算机视觉大会会议论文集*, 第239–249页, 2025.

陈, Z., Badrinarayanan, V., Lee, C.-Y., 和 Rabinovich, A. Gradnorm: 深度多任务网络中用于自适应损失平衡的梯度归一化。在 国际

机器学习会议, pp. 794–803. PMLR, 2018.

Cheng, J., Xiong, G., Qiao, R., Li, L., Guo, C., Wang, J., Lv, Y., and Wang, F.-Y. Stop summation: Min-form credit assignment is all process reward model needs for reasoning. *神经信息处理系统进展*, 38:131646–131671, 2026.

Christiano, P. F., Leike, J., Brown, T., Martic, M., Legg, S., and Amodei, D. Deep reinforcement learning from human preferences. *神经信息处理系统进展*, 30, 2017.

Comanici, G., Bieber, E., Schaekermann, M., Pasupat, I., Sachdeva, N., Dhillon, I., Blistein, M., Ram, O., Zhang, D., Rosen, E., 等. Gemini 2.5: 通过高级推理、多模态、长上下文和下一代智能体能力推动前沿。 *arXiv预印本 arXiv:2507.06261*, 2025.

Deng, Y., Hsu, I., Yan, J., Wang, Z., Han, R., Zhang, G., Chen, Y., Wang, W., Pfister, T., Lee, C.-Y., 等人. 监督强化学习：从专家轨迹到逐步推理。 *arXiv预印本 arXiv:2510.25992*, 2025.

Gu, Y., Dong, L., Wei, F., 和 Huang, M. MiniLLM: 大型语言模型的知识蒸馏。见 第十二届国际学习表征会议, 2024. 网址<https://openreview.net/forum?id=5h0qf7IBZZ>.

Guha, E., Marten, R., Keh, S., Raoof, N., Smyrnis, G., Bansal, H., Nezhurina, M., Mercat, J., Vu, T., Sprague, Z., 等人. Openthoughts: 推理模型的数据配方。 *arXiv预印本 arXiv:2506.04178*, 2025.

Guo, D., Yang, D., Zhang, H., Song, J., Zhang, R., Xu, R., Zhu, Q., Ma, S., Wang, P., Bi, X., 等. Deepseek-r1: 通过强化学习激励LLM的推理能力。 *arXiv预印本 arXiv:2501.12948*, 2025.

Jain, J., Yang, Z., Shi, H., Gao, J., 和 Yang, J. 通过视觉嵌入蒸馏提升多模态LLM的视觉感知。In 第三十九届神经信息处理系统年会, 2025.

Kim, J., Kim, K., Seo, S., 和 Park, C. Compodistill: 多模态LLM中用于组合推理的注意力蒸馏。 *arXiv预印本 arXiv:2510.12184*, 2025.

Kim, Y. 和 Rush, A. M. 序列级知识蒸馏, 2016. URL<https://arxiv.org/abs/1606.07947>.

- Lyu, S., 等. Tulu 3: 推动开放语言模型后训练的前沿. *arXiv 预印本 arXiv:2411.15124*, 2024.
- Lee, D. B., Lee, S., Park, S., Kang, M., Baek, J., Kim, D., Wagner, D., Jin, J., Lee, H., Bocklet, T., 等. 重新思考多领域测试时扩展的奖励模型. *arXiv 预印本 arXiv:2510.00492*, 2025.
- 李, W. 和李, Y. 基于Q值排序的过程奖励模型. 在国际学习表示大会上, 卷2025, 页14708–14726, 2025年.
- Li, Z., Yu, W., Huang, C., Liu, R., Liang, Z., Liu, F., Che, J., Yu, D., Boyd-Graber, J., Mi, H., 等. 基于推理分解的自我奖励视觉语言模型. *arXiv 预印本 arXiv:2508.19652*, 2025.
- Muralidharan, S., Turuvekere Sreenivas, S., Joshi, R., Cho-chowski, M., Patwary, M., Shoybi, M., Catanzaro, B., Kautz, J., and Molchanov, P. 通过剪枝和知识蒸馏的紧凑语言模型. *神经信息处理系统进展*, 37:41076–41102, 2024.
- Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C., Mishkin, P., Zhang, C., Agarwal, S., Slama, K., Ray, A., et al. 使用人类反馈训练语言模型遵循指令. *神经信息处理系统进展*, 35:27730–27744, 2022.
- Rafailov, R., Sharma, A., Mitchell, E., Manning, C. D., Ermon, S., and Finn, C. 直接偏好优化: 你的语言模型其实是一个奖励模型. *神经信息处理系统进展*, 36: 53728–53741, 2023.
- Rahmanzadehgervi, P., Bolton, L., Taesiri, M. R., and Nguyen, A. T. 视觉语言模型是盲目的: 未能将详细的视觉特征翻译成文字. *arXiv preprint arXiv:2407.06581*, 2024.
- 邵、王、朱、徐、宋、毕、张、张、李、吴等人. Deepseekmath: 突破开放语言模型中的数学推理极限. *arXiv 预印本 arXiv:2402.03300*, 2024年.
- 宋Y., 欧T., 孔Y., 李Z., Neubig G., 岳X. VisualPuzzles: 将多模态推理评估与领域知识解耦. *arXiv 预印本 arXiv:2504.10342*, 2025. 网址 <https://arxiv.org/abs/2504.10342>.
- 陶里, R., 古拉贾尼, I., 张, T., 杜布瓦, Y., 李, X., 格斯特林, C., 梁, P., 和桥本, T. B. Stanford alpaca: 一种遵循指令的llama模型. https://github.com/tatsu-lab/stanford_alpaca, 2023.
- Team, G., Riviere, M., Pathak, S., Sessa, P.G., Hardin, C., Bhupatiraju, S., Hussenot, L., Mesnard, T., Shahriari, B., Ramé, A., 等. Gemma 2: 在实用规模上改进开放语言模型. *arXiv 预印本 arXiv:2408.00118*, 2024. Team, K., Du, A., Gao, B., Xing, B., Jiang, C., Chen, C., Li, C., Xiao, C., Du, C., Liao, C., 等. Kimi k1. 5: 用LLM扩展强化学习. *arXiv 预印本 arXiv:2501.12599*, 2025. Team, Q. Qwq-32b: 拥抱强化学习的力量, 2025年3月. URL <https://qwenlm.github.io/blog/qwq-32b/>.
- Wang, K., Pan, J., Shi, W., Lu, Z., Ren, H., Zhou, A., Zhan, M., and Li, H. 使用Math-Vision数据集测量多模态数学推理. In 第38届神经信息处理系统大会数据集与基准测试轨, 2024. URL <https://openreview.net/forum?id=QWTCcxMpPA>.
- Xi, Z., Chen, W., Hong, B., Jin, S., Zheng, R., He, W., Ding, Y., Liu, S., Guo, X., Wang, J., et al. 通过反向课程强化学习训练大型语言模型进行推理. *arXiv 预印本 arXiv:2402.05808*, 2024.
- 肖?, 孙?, 刘?, 王?. LogicVista: 视觉上下文中的多模态大语言模型逻辑推理基准, 2024年. URL <https://arxiv.org/abs/2407.04973>.
- Yang, A., Zhang, B., Hui, B., Gao, B., Yu, B., Li, C., Liu, D., Tu, J., Zhou, J., Lin, J., 等. Qwen2.5-math技术报告: 通过自我改进走向数学专家模型. *arXiv 预印本 arXiv:2409.12122*, 2024.
- Yang, A., Li, A., Yang, B., Zhang, B., Hui, B., Zheng, B., Yu, B., Gao, C., Huang, C., Lv, C., 等. Qwen3技术报告. *arXiv 预印本 arXiv:2505.09388*, 2025.
- Yoon, E., Yoon, H. S., Eom, S., Han, G., Nam, D., Jo, D., On, K.-W., Hasegawa-Johnson, M., Kim, S., and Yoo, C. Tlcr: 用于细粒度人类反馈强化学习的Token级连续奖励. 在计算语言学协会会议论文集: *ACL 2024*, 第14969–14981页, 2024年.
- Yoon, E., Yoon, H. S., Jang, J., Eom, S., Dai, Q., Luo, C., Hasegawa-Johnson, M. A., and Yoo, C. D. Pacr: 渐进式上升的置信度奖励用于大语言模型推理. *arXiv preprint arXiv:2510.22255*, 2025a.

Yoon, H. S., Yoon, E., Hasegawa-Johnson, M. A., Kim, S., 和 Yoo, C. D. ConfPO: 利用策略模型置信度进行偏好优化中的关键令牌选择. 见于第四十二届国际机器学习大会, 2025b. 网址 <https://openreview.net/forum?id=ZG7bkgp6ScT>.

Yoon, H. S., Yoon, E., Hong, J. W., Eom, S., Koo, G., Hasegawa-Johnson, M., Dai, Q., Luo, C., 和 Yoo, C. D. Pdcr: 感知分解的置信度奖励用于视觉-语言推理. *arXiv预印本 arXiv:2605.13467*, 2026.

Yue, X., Zheng, T., Ni, Y., Wang, Y., Zhang, K., Tong, S., Sun, Y., Yu, B., Zhang, G., Sun, H., Su, Y., Chen, W., and Neubig, G. Mmmu-pro: 一个更稳健的多学科多模态理解基准. *arXiv 预印本 arXiv:2409.02813*, 2024. Zhang, D., Zhang, S., Yang, Z., Zhu, Z., Zhao, Z., Cao, R., Chen, L., and Yu, K. Progrm: 通过进度奖励构建更好的 GUI 代理. *arXiv 预印本 arXiv:2505.18121*, 2025. Zhang, R., Jiang, D., Zhang, Y., Lin, H., Guo, Z., Qiu, P., Zhou, A., Lu, P., Chang, K.-W., Qiao, Y., et al. Math-Verse: 你的多模态大语言模型真的能看懂数学问题中的图表吗? In 欧洲计算机视觉会议, 第 169–186 页. Springer, 2024.

A. 自适应缩放因子 $\eta_{\text{VGS}}(\gamma)$ 的分析

在本节中，我们提供用于近似自适应缩放因子的分析推导和实证依据 $\eta_{\text{VGS}}(\gamma)$ 作为一个常数。

解析推导。回顾公式中归一化因子的定义，来自式15。通过展开分母中的平方范数，我们可以将 $\eta_{\text{VGS}}(\gamma)$ 表示为梯度幅度和角度 ϕ 之间的函数：

$$\begin{aligned}\eta_{\text{VGS}}(\gamma) &\triangleq \frac{\|\nabla \mathcal{L}_{\text{Standard}}\|_2}{\|\nabla \mathcal{L}_{\text{Standard}} + \gamma \nabla \mathcal{L}_{\text{Vis}}\|_2} \\ &= \frac{\|\nabla \mathcal{L}_{\text{Standard}}\|_2}{\sqrt{A + B + C}},\end{aligned}\tag{23}$$

其中：

$$\begin{aligned}A &= \|\nabla \mathcal{L}_{\text{Standard}}\|_2^2, \\ B &= \gamma^2 \|\nabla \mathcal{L}_{\text{Vis}}\|_2^2, \\ C &= 2\gamma \|\nabla \mathcal{L}_{\text{Standard}}\|_2 \|\nabla \mathcal{L}_{\text{Vis}}\|_2 \cos \phi,\end{aligned}$$

and ϕ 表示标准梯度 $\nabla \mathcal{L}_{\text{Standard}}$ 与视觉梯度 $\nabla \mathcal{L}_{\text{Vis}}$ 之间的夹角

计算式23的每一步都需要梯度范数计算，带来了计算开销。为缓解这一问题，我们跟踪了各组成部分（ $\|\nabla \mathcal{L}_{\text{Standard}}\|_2$ 、 $\|\nabla \mathcal{L}_{\text{Vis}}\|_2$ 和 $\cos \phi$ ）在整个训练过程中的演变。如图7所示，我们观察到这些值在训练中保持相对恒定。因此，得到的比率 $\eta_{\text{VGS}}(\gamma)$ 在整个训练过程中表现出高度的稳定性。




图7. 梯度范数分量的演变。我们跟踪了标准梯度（紫色）和视觉梯度（绿色）的幅值，以及它们之间的余弦相似度（蓝色），用于Qwen3-VL-2B-Instruct 学生模型在标准同策略蒸馏过程中的表现。这三个分量在训练步骤中均表现出稳定性，从而证明了我们将自适应缩放因子 $\eta_{\text{VGS}}(\gamma)$ 近似为固定常数以降低计算开销的合理性。

基于这一观察，我们将 $\eta_{\text{VGS}}(\gamma)$ 视为一个由模型架构和 γ 确定的固定超参数。在使用 $\gamma = 2.0$ 的主要实验中，我们采用了预计算的平均值：

- Qwen3-VL-2B-Instruct: $\eta_{\text{VGS}} = 0.41$
- Qwen3-VL-4B-Instruct: $\eta_{\text{VGS}} = 0.36$

这个近似方法在无需运行时成本的情况下保持了梯度归一化的稳定性优势。

B. 实现细节

B.1. 教师模型训练

为了生成高质量的蒸馏推理轨迹，我们使用分组相对策略优化（GRPO）训练一个教师模型。我们以 Qwen3-VL-8B-Instruct初始化教师模型，并在Vision-SR1-47K数据集上微调2个训练轮数。这一强化学习阶段确保教师模型提供稳健、可验证的推理链，而不仅仅是最终答案。我们使用TRL代码库进行所有GRPO实验。教师训练阶段的具体超参数见表3。

表3. 教师模型训练超参数（GRPO）。教师模型（Qwen3-VL-8B-Instruct）在Vision-SR1-47K上训练2个训练轮数。

超参数	值
优化	
优化器	AdamW
学习率	1e-6
权重衰减	1e-2
学习率调度	常数
训练轮数	2
全局批次大小	128
冻结视觉编码器	否
强化学习/推出配置	
推出批量大小	512
推出大小 (G)	8
推出温度	1.0
Rollout Top-p	0.99
最大输入提示长度	12800
最大响应长度	2048
使用KL损失	假

B.2. 训练框架与超参数

表4. 关键超参数用于在策略蒸馏训练一个模型并评估。

超参数	值
优化与训练	
优化器	AdamW
学习率	1e-6
权重衰减	1e-2
学习率调度	常数
训练轮数	1
全局批次大小	512
冻结视觉编码器	否
在策略展开	
推出温度	1.0
Rollout Top-p	1.0
最大输入提示长度	16384
最大响应长度	2048
VGS特定 (我们的)	
引导系数 (γ)	2.0
正则化权重 (λ)	0.01




图8. 超参数敏感性分析. 我们评估关键超参数对学生模型平均准确率的影响。(a) 改变引导系数 γ (针对 Qwen3-VL-2B-Instruct): 该方法在广泛的 γ 取值范围内表现出鲁棒性, 始终优于标准同策略蒸馏基线 (灰色虚线)。(b) 改变语言保持权重 λ (针对 Qwen3-VL-4B-Instruct): 较小的非零正则化 (例如 $\lambda = 0.01$) 可获得最高性能, 证实语言保持 (LP) 项有效缓解破坏性干扰, 同时不抑制视觉信号。

B.3. 视觉梯度引导 (VGS) 特定超参数的敏感性分析

B.4. 训练与推理的提示模板

为确保教师模型与学生模型策略之间的结构对齐, 我们在所有训练阶段 (教师GRPO、学生模型在策略蒸馏以及 VGS) 中均使用统一系统提示。该提示强制采用严格的思维链 (CoT) 格式, 要求模型在生成最终答案之前, 将其推理过程明确限定在 `<reason>` 和 `</reason>` 标签内。使用的标准模板如下:

训练与推理的推理模板

系统:

用户与助手之间的对话。用户提出问题, 助手进行解答。助手首先在脑海中思考推理过程, 然后向用户提供答案。推理过程应包含在 `<reason>` `</reason>` 标签内。最终答案必须放在 `\boxed{\}` 中。

用户:

{图像}{问题}




图9. 训练成本对比. VGS因需要两次前向传播来分离视觉梯度，导致每步训练时间略有 $1.375\times$ 增加。

C. 计算成本开销

我们在图9中分析我们方法的计算效率。VGS引入了适度的开销，使每步训练时间相较于标准在线蒸馏增加了约 $1.375\times$ 。这一增加源于需要额外进行一次非图像条件下的前向传播来计算分解后的视觉梯度。考虑到引导机制带来的显著性能提升，我们认为这是一个微小且可接受的代价。




图10. 不同视觉依赖程度下优化引导的影响。平均准确率比较：语言引导、标准同策略蒸馏和视觉梯度引导。(a) 在高度视觉依赖的基准上，优先考虑视觉子空间（VGS）显著优于基准线，而依赖语言先验则会主动降低性能。(b) 在低视觉依赖和 (c) 纯文本基准上，所有方法的性能保持一致，这证实了VGS在视觉定位为主要瓶颈的情况下带来收益，同时不会损害模型的核心文本推理能力。

D. 视觉梯度引导何时最有效？

为了分析视觉梯度引导（VGS）在何时能带来最大收益，我们根据模型对视觉上下文的依赖程度，在多个基准上对模型进行了评估（Wang 等, 2025）。图 10 按视觉依赖程度分组，比较了语言引导、标准同策略蒸馏和视觉梯度引导在不同引导系数下的表现。

- **高视觉依赖性（MMM-Pro, LogicVista）**。明显的上升趋势出现（语言引导 < 标准OPD < VGS），优先考虑视觉子空间可带来一致的收益。
- **低视觉依赖（Geo3K, We-Math）**。不同方法之间的性能差异极小。当文本提示包含足够信息以推导出答案时，优化轨迹的影响微乎其微。
- **纯文本（MATH500, AIME25, OlympiadBench）**。所有方法均表现一致。这表明在蒸馏过程中优先考虑视觉子空间并不一定会损害模型的核心纯文本推理能力。

总之，VGS在需要强多模态基础的任务上始终优于标准OPD，同时不会牺牲在低依赖性纯文本任务上的性能。

表5.视觉-语言推理基准测试的主要结果。我们比较了视觉梯度引导（VGS）与标准整体基线的蒸馏性能。所有学生模型（2B和4B）均从同一个使用GRPO训练的Qwen3-VL-8B-Instruct教师模型蒸馏而来。VGS在所有基准测试中均持续优于标准方法，在贪婪解码（Top-1准确率）中取得了更高的准确率。

基准	教师模型 (GRPO训练)	初始 学生模型	标准 在策略蒸馏	VGS 在策略蒸馏（我们的）	Adaptive-VGS 在策略蒸馏（我们的）
	Top-1准确率	Top-1准确率	Top-1准确率	Top-1准确率	Top-1准确率
	(贪婪)	(贪婪)	(贪婪)	(贪婪)	(贪婪)
	8B	2B	Qwen3-VL-8B-Instruct → Qwen3-VL-2B-Instruct		
MMMU-Pro-4	62.03	34.51	45.83	48.07	48.40
LogicVista	60.01	36.83	45.53	48.88	<u>48.31</u>
MathVerse-VD	79.63	35.88	56.02	<u>58.10</u>	59.72
MathVerse-VO	73.85	35.32	54.59	<u>56.19</u>	57.11
VisualPuzzles	43.15	13.36	28.08	<u>30.64</u>	33.99
MathVision	44.14	14.28	24.14	25.59	<u>25.16</u>
VlmsAreBlind	66.79	49.03	51.86	54.11	<u>53.00</u>
Average	61.37	31.32	43.74	<u>46.10</u>	46.53

E. 自适应词元级视觉梯度引导

我们的主要公式对所有标记应用单一固定的引导系数 γ 。一个自然的扩展是让视觉强调在标记级别上变化，根据每个标记依赖视觉证据的程度来缩放引导强度。为此，我们探索了一个完全自适应的视觉梯度引导（VGS）目标函数，该函数根据每个标记的视觉依赖度评分（VDS_t，公式12）动态缩放引导系数 γ_t 。

形式上，修改我们的目标函数，如公式 17，自适应目标函数的定义如下：

$$\ell_{\text{Adaptive}}(\tau) \triangleq \frac{1}{|\tau|} \sum_{t=1}^{|\tau|} \left(\ell_{\text{Standard}}(\tau) + \gamma_t \ell_{\text{Vis}}(\tau) + \lambda \ell_{\text{LP}}(\tau) \right), \quad (24)$$

其中，词元级引导系数 γ_t 动态调整：

$$\gamma_t = \begin{cases} 0, & \text{VDS}_t \leq Q_{0.4} \quad (\text{no visual correction}), \\ \gamma/2, & Q_{0.4} < \text{VDS}_t \leq Q_{0.7} \quad (\text{moderate correction}), \\ \gamma, & \text{VDS}_t > Q_{0.7} \quad (\text{maximum visual steering}), \end{cases} \quad (25)$$

其中 $Q_{0.4}$ 和 $Q_{0.7}$ 表示视觉依赖度评分分布的第40和第70百分位数阈值。直观上，这会将引导预算分配给真正需要视觉定位的词元，同时保持低依赖词元不变。

如表5所示，这种自适应公式略优于我们原始的固定尺度方法（即 $\gamma = 2.0$ ），取得了最高的总体平均准确率。这表明，将引导强度与每个token的视觉需求相匹配，可以在过度应用均匀系数的基础上带来适度的额外收益。

F. 生成推理的定性比较

在本节中，我们对提出的**视觉梯度引导（VGS）**与标准的单一在策略蒸馏基线进行了并排比较。所有展示的示例均由Qwen3-VL-2B-Instruct从Qwen3-VL-8B-Instruct 教师模型蒸馏生成。这些示例突显了将梯度明确引导至视觉子空间的核心优势。如下面的图表所示，标准基线常常表现出一种特定的失败模式：它生成逻辑上连贯的推理链，但这些推理链基于错误的视觉提取（以**红色**高亮显示）。相比之下，VGS引导学生模型准确地将推理锚定在视觉输入上（以**绿色**高亮显示）。


G. 局限性

虽然视觉梯度Steering (VGS) 显著提高了推理可靠性，我们承认两个主要限制 s.

训练吞吐量开销。VGS的核心机制需要分解教师模型的输出分布，这要求在每次训练步中额外进行一次无视觉输入的前向传播。如第C节所述，与标准蒸馏相比，这会带来约 1.375x的计算开销。

对教师模型校准的依赖。VGS 的操作前提是教师模型的多模态和单模态分布是可区分的。它依赖于这两者之间的对比信号来引导学生模型。因此，如果教师模型出现模式崩溃，即视觉输入对输出分布没有影响（即 $\nabla \mathcal{L}_{\text{vis}} \approx 0$ ），那么 VGS 实际上退化为标准蒸馏。我们的方法增强了视觉定位的迁移，但无法纠正教师模型本身存在的根本性感知盲区。

由标准同策略蒸馏生成的样本1



问题：这两个圆是否相互接触？答案为是/否

真实值：否


生成：

<推理>

两个圆上下排列，之间没有可见间隙。由于它们在一个点上接触（底部的圆与顶部的圆在重叠边缘处接触），因此被视为相触。

</reason>

由VGS在线策略蒸馏（我们的方法）生成的样本1



问题：两个圆是否相互接触？答案为是/否

真实值：否


生成：

<推理>

图像中的两个圆上下排列，但它们并未相互接触。它们之间有一个明显的空隙。接触意味着它们的边缘在某一点相交，但这里它们被一个间隙隔开。

</推理>

标准同策略蒸馏生成的样本2



问题: 计算图像中的五边形数量。用大括号内的数字回答, 例如 `\boxed{3}`。

真实值: 9


生成:

<reason>

图片展示了一个经典的奥运五环标志, 由五个相互交织的五边形组成。每个五边形颜色各异: 红色、橙色、蓝色、绿色和紫色。图中没有其他五边形。因此, 五边形的总数为5个。

</reason > 5

由VGS在线策略蒸馏 (我们的方法) 生成的样本2



问题: 数一数图中的五边形数量。用花括号中的数字回答, 例如 `\boxed{3}`。

真实值: 9

生成:

<推理>

数一下五边形在图像中。图像显示一排五边形, 每个颜色不同。逐个数它

ne:

1. 红色五边形 2. 橙色五边形 3. 蓝色五边形 4. 绿色五边形 5. 紫色五边形 6. 灰色五边形 7. 棕色五边形 8. 粉色五边形 9. 黄色五边形 总共有9个五边形。</推理>

> 9



由标准同策略蒸馏生成的样本3



问题: 以下哪个陈述最有力地得到了图像中所示地图中包含的信息的支持?

选择:

(a) 哥萨克社区虔诚地信奉保守派的俄罗斯东正教。(b) 哥萨克军团经常反抗俄罗斯帝国的中央集权权威。(c) 哥萨克军事单位由技艺高超的骑兵战士组成。(d) 哥萨克民族认同是通过与帝国边疆的非俄罗斯民族通婚而形成的。(d)

生成:

<推理>

所显示的地图是一个“前俄罗斯帝国主要哥萨克军团的地图。”它突出了哥萨克所在的各个地区社区是 ce 输入。然而，地图没有提供关于以下内容的任何信息：

- 宗教实践 (A) – 该地图未显示任何宗教归属或信仰。
- 反抗中央权威 (B) – 该地图未显示任何叛乱或抵抗的证据。
- 军事技能 (C) – 该地图未提供关于哥萨克部队军事能力或训练的任何信息。
- 民族身份 (D) – 该地图未显示任何关于通婚或民族融合的信息。

由于地图只显示了哥萨克军团的位置，且没有任何选项能直接由地图内容支持，我们必须根据关于哥萨克的普遍历史知识，选择最可能正确的选项。

哥萨克是一个半游牧民族，在俄罗斯帝国的军事和政治历史中扮演了重要角色。他们以武艺高强著称，并经常参与边疆冲突。虽然地图并未

.. “提供直接证据，选项C（哥萨克军事单位由技艺高超的骑兵组成）是一个关于哥萨克的文献记载充分的事实，并且它最受普遍历史知识的坚实支持，尽管地图上并未直接说明。

因此，最佳答案是C。 </推理>

(c)

由VGS在线策略蒸馏（我们的）生成的样本3



他以下陈述最有力地得到了由该地图中所包含的信息的支持，该地图显示在

图片？

选项：

- (a) 哥萨克社区虔诚地信奉着保守的俄罗斯东正教。(b) 哥萨克军团经常反抗俄罗斯帝国的中央集权。
(c) 哥萨克军事单位由技艺高超的骑兵战士组成。(d) 哥萨克民族认同是通过与帝国边疆的非俄罗斯民族通婚而形成的。(d)

生成：

<理由>

所示地图是“前俄罗斯帝国主要哥萨克军团地图”。它突出了哥萨克社区所在的各个地区，如顿河、库班、捷列克、乌拉尔、奥伦堡、七河地区、西伯利亚、外贝加尔、阿穆尔、乌苏里、伊尔库茨克和雅库茨克地区。

- 选项A：该地图未提供关于哥萨克人宗教信仰或信仰的任何信息。地图不支持这一点。
- 选项B：地图未提供任何关于叛乱或反抗中央权威的信息。地图不支持这一点。
- 选项C：地图未提供任何关于哥萨克部队的军事技能或构成的信息。地图不支持这一点。
- 选项D：地图显示了哥萨克军团位于历史上曾是边疆地区的区域，包括拥有大量非俄罗斯人口的地区（例如西伯利亚、外贝加尔、乌拉尔）。这表明哥萨克民族认同是通过在帝国边疆与非俄罗斯民族通婚而形成的。基于历史背景，这是一个合理的推断，而且

地图支持了这样一种观点，即哥萨克人通常位于边疆地区，在那里他们与其他民族群体互动。

因此，地图中包含的信息最有力地支持的陈述是D。 </reason>

(d)

通过标准同策略蒸馏生成的样本4



问题: 这位患者患有什么疾病? 选项: (a) 肋骨骨折 (b) 内脏逆位 (c) 胸腔积液 (d) 肩关节脱位**(b)**

生成:
<推理>

图像显示胸部X光片, 可清晰观察到肺部、心脏和肋骨。肋骨未见明显骨折线或畸形, 肩关节形态正常。心脏位于正常位置, 且未见胸腔积液征象(积液会表现为肋膈角变钝或“模糊”外观)。肩关节亦保持完整。

内脏逆位是一种器官在身体中镜像反转的病症(例如, 心脏位于右侧), 但在本X光片中不可见。肋骨骨折会显示骨折线, 但图像中未出现。肩关节脱位会显示明显的脱位, 但图像中未出现。胸腔积液会显示肋膈角变钝或出现“模糊”影像, 但此处未出现。

根据选项, 最可能的病症是**胸腔积液**, 因为这是胸部X光中的常见发现, 可能表现为“模糊”或“变钝”影像, 但在此情况下, 图像显示肺部清晰, 没有积液的迹象。

等等, 让我重新检查一下。图像显示肺部清晰, 没有胸腔积液的迹象。肋膈角清晰, 没有液体聚集。因此, 没有一个选项完全符合。

但再次审视选项, **胸腔积液**是最可能的答案, 因为这是一种常见疾病, 可在胸部X光上看到, 并常伴有呼吸急促或咳嗽等症状。图像显示正常胸腔, 因此胸腔积液并非最佳选择。

实际上, 图像 显示正常的胸部X光, 因此没有选项是正确的。但由于我们必须选择 ,

胸腔积液是给定选项中最可能的答案。因此, 最佳答案是C。

</reason> (c)



由VGS在线策略蒸馏生成的样本4（我们的）



问题: 这位患者患有什么疾病? 选项: (a) 肋骨骨折 (b) 内脏逆位 (c) 胸腔积液 (d) 肩关节脱位**(b)**

生成:
<推理>

图像显示一张胸部X光片，清晰可见肺部、肋骨和肩部。肋骨上未见明显骨折线或畸形，提示无肋骨骨折。双肩形态正常，未见脱位迹象。肺野清晰，无胸腔积液征象（例如胸腔内液体体积聚，表现为肋膈角变钝或“模糊”的影像）。最可能的诊断为内脏逆位，这是一种先天性状况，即器官位置与正常相反。在内脏逆位中，心脏位于对侧，肺部亦呈反转排列。这是一种常见情况，通常不伴随症状。图像显示正常的胸部X光，未见其他选项所提示的征象。 </reason>
(b)

